

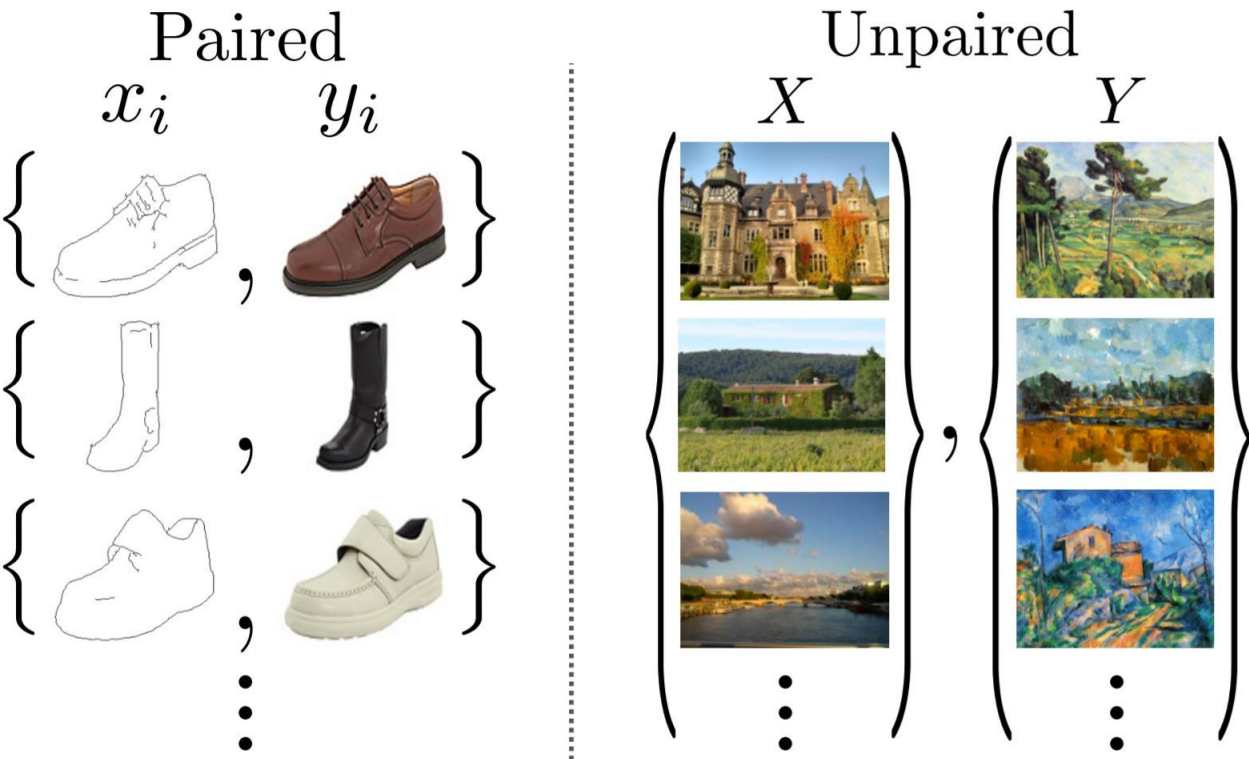
CycleGAN:Unpaired Image-to-Image Translation using Cycle-Consistent Adversarial Networks

摘要

图像到图像转换通常需要成对训练数据。但是对于很多任务而言,成对数据不可获取.本文提出在没有成对数据情况下把源域数据X映射到目标域Y。我们的目标是学习映射 $G:X \rightarrow Y$ 使得 $G(X)$ 和Y的分布难以区分，由于映射高度不可控制,我们引入相反的映射 $F:Y \rightarrow X$,得到一个循环一致损失使得 $F(G(X))$ 近似于X.实验结果表明算法具有优势.

简介

很多图像翻译的工作需要配对数据,如下图左边



,但是配对数据有时候不可获取如图中右半部分.因此需要算法将不配对的两个数据源进行转换。

CycleGAN

算法框架如下:




Figure 3: (a) Our model contains two mapping functions $G : X \rightarrow Y$ and $F : Y \rightarrow X$, and associated adversarial discriminators D_Y and D_X . D_Y encourages G to translate X into outputs indistinguishable from domain Y , and vice versa for D_X , F , and X . To further regularize the mappings, we introduce two “cycle consistency losses” that capture the intuition that if we translate from one domain to the other and back again we should arrive where we started: (b) forward cycle-consistency loss: $x \rightarrow G(x) \rightarrow F(G(x)) \approx x$, and (c) backward cycle-consistency loss: $y \rightarrow F(y) \rightarrow G(F(y)) \approx y$

同时学习两个映射关系 $G:X \rightarrow Y$ 和 $F:Y \rightarrow X$,两个生成器和两个判别器.判别器 D_Y 促进 G 把 X 转换为 Y , D_X 则保证 F 把 Y 转换为 X .进一步,为了保证算法有效性,使用两个cycle consistency losses.

前向cycle-consistency loss: $x \rightarrow G(x) \rightarrow F(G(x))$ 近似于 x

反向cycle-consistency loss: $y \rightarrow F(y) \rightarrow G(F(y))$ 近似于 y

优化目标(损失函数)

这里有两个生成网络和两个对抗网络,并且包含两部分循环一致损失, 因此总损失包含对抗损失和循环一致损失, 其中循环一致损失是L1损失。